

경구약제 객체 탐지

Codeit – AI 04기 초급 프로젝트

김명환 – 모델 아키텍처 설계

김민혁 – 실험 설계 및 파라미터 튜닝

이건희 – 프로젝트 총괄 관리 및 파이프라인
구축

프로젝트 소개

프로젝트 개요


기대 효과

미션 개요

- 촬영한 약물 이미지에서 **최대 4개의 알약을 동시에 검출하고 분류**
- 사용자에게 약물 정보 및 상호작용 경고를 제공하는 AI 시스템을 개발

기대 효과

- 1. **오용 예방 및 안전성 강화**
사용자가 촬영한 알약 이미지를 기반으로, 잘못된 약 복용이나 상호작용 위험을 알림.
- 2. **사용자 편의성 향상**
스마트폰 촬영만으로 약물 정보와 경고를 바로 제공, 복용 관리가 쉬워짐.



데이터

데이터 정보

주요 문제점


해결 방안

데이터 정보

전체 데이터셋 정보

- 데이터셋 명 : 약품식별 인공지능 개발을 위한 경구약제 이미지데이터
- 제공기관 : 서울특별시 보라매병원
- 구축년도 : 2021년
- 데이터 특성 : 실험실 통제 환경에서 촬영된 이미지

1. 데이터 구축 규모				
구분	구축목표		구축달성	
	1종당 이미지 수	합계	1종당 이미지 수	합계
단일 경구약제 1,000종	1,250	1,250,000	1,296	1,296,000
단일 경구약제 4,000종	200	800,000	수량 다양화 (1,296/324/216)	1,482,975
경구약제 조합 5,000조합	3	15,000	3	15,003
총 합계		2,065,000		2,793,978
목표대비 성과율	100%		135%	




이미지 메타데이터 스키마

- 이미지 기본정보: 해상도(Resolution), 파일명, 크기
- 촬영 조건 : 배경색상, 조명색상, 카메라 각도
- 약제 정보 : 제품코드, 제품명, 성분명, 제조사
- 바운딩 박스 : COCO 포맷(Format) 어노테이션(Annotation)

Annotation 보유 정보

- Images : 이미지 메타데이터
- Annotations : 바운딩 박스 좌표 및 클래스 정보
- Categories : 약제 카테고리 정의



AI-Hub의 데이터셋 중 초급 과제를 위하여 코드잇 배포용 데이터
Train 4481 (Train 3169(0.7), Val 1312 (0.3)), Test 843, 카탈로그 73



Train-Validation 분할 전략

데이터 분할 전략

- 데이터 증강 전 베이스 파이프 라인에 따른 진행 시,
데이터 셋의 클래스가 불균형 되어 있으므로 랜덤 분할 시 Train 혹은 Validation에 빠질 수가 있다.
- 각 클래스 별로 30%를 분할 하는 전략을 취하여 학습이나 검증 시 데이터가 빠지지 않도록 하였다.



✖ 주요 문제점들


1. Class별 데이터 불균형

- 특정 class의 알약의 경우, 객체 자체가 부족함.
- 알약 개수의 심한 편차 발견, long-tail 문제

해당 과정에서 아래와 같은 문제 발생

- 소수 클래스에 대한 학습 부족
- 과적합(Overfitting) 발생
- 모델의 불안정성 :

소수 클래스의 몇몇 데이터가 학습 과정에 **과도한 영향**을 미칠 수 있음





해결 방안

1. Class별 데이터 불균형

데이터 추가 확보 및 증강 : AI-HUB의 경구약제조합 1, 3 추가

1.1 특정 클래스의 객체 수 부족

해결 전 :

- 특정 클래스에 해당하는 객체의 수가 현저히 부족한 문제를 확인
- 해당 클래스를 충분히 학습하지 못해, 해당 객체를 제대로 탐지하지 못하는 원인

해결 후 :

- 데이터 추가를 통해 최소 객체의 수가 약 30개로 늘어남

1.2 클래스별 데이터 불균형






해결 전 :

- KDE 그래프에서 볼 수 있는 것 처럼, **Right-Skewed 분포**를 보여주고 있음.
- 일부 클래스만 데이터가 많고 나머지는 적은 분포

해결 후 :

- **Right-Skewed** 되지 않고, 비교적 안정적인 데이터 분포로 변화함

이 외에도, 회전, 등의 데이터 증강을 통해 추가적으로 데이터 불균형을 해소 (증강 데이터에 따른 테스트 필요)



✖ 주요 문제점들

2. 라벨데이터 오류

- 약 10%의 이미지에 bbox와 class데이터가 존재하지 않음.
- 소수의 bbox의 위치 오류
- label자체의 오류가 존재함.
- Out of Domain(OOD) 문제 존재
 - kaggle데이터에는 존재하지 않음.



< bound box 존재 ✖ >



< bound box 위치 ✖ >



< Out of Domain >



- 데이터 추가 확보 과정을 통해 해결
- 실제 데이터에서는 bbox 생성되었는데, 신뢰도가 낮을 경우, Unknown으로 변경하여 기존에 없는 데이터임을 표현 가능
- 앙상블 모델을 이용하여, 예측 불확실성이 높아지는 것을 막거나 감지할 수 있음.
 - ➔ 앙상블 모델을 실험한 이유




해결 방안

2. 라벨데이터 오류


10%의 이미지에 bbox와 class데이터가 존재하지 않음

아래 두 가지 방안의 해결방안 제시

- Bbox가 없는 이미지에 객체를 제거하여, 데이터 학습



- Bbox를 준지도학습을 통해, pseudo-label을 생성한 후 데이터 학습



✕ 주요 문제점들

3. Missing Information 문제


- 20이 적힌 면의 사진만으로는 약의 이름을 정확히 분류가 매우 어려움
- 리피로우정과 비유피정 모두 20이 적힌 면에 원형의 흰색 정제약이기 때문에, 분류 문제를 해결하기 위해서는 해상도가 높은 디테일한 분석이 가능한 모듈 선정 필요



라피로우정



비유피정






알약 데이터 증강 전략

3. TL1와 TL3 조합 데이터 에서 알약을 분리

3.1 알약을 클래스 별로 분류

- 알약 당 100개의 샘플을 랜덤하게 추출.
- 잘못된 라벨링 혹은 잘못된 박스 등이 존재함.
- 히스토그램 평균에 따른 1차 분류
 - 각 알약 클래스별 히스토그램 평균 값
 - 평균의 표준편차가 2.0 이상이라면 노이즈로 판단.
- 2차 시각적으로 노이즈 알약 제거
- 해결 후 :
 - 노이즈 처리된 데이터 셋을 만들었음
 - 향후 해당 데이터 셋을 사용한 학습 및 결과 확인 필요





데이터 증강 주의사항

- 알약의 특성

알약은 모양이 비슷하고 색 혹은 음각되어 있는 글자로 구분됨

- 데이터 증강시 이를 고려하지 않는다면 되려 학습율이 떨어질수 있음
- 금기 : 과도한 밝기, 색 조정, 좌우, 상하 반전
- 제안 : 회전, 확대, 축소


비슷한 종류의 다른 약



데이터 증강에 따른 색변화



병용 금기 약물 정보 분석



약물 정보:

- EDI 코드: di_edi_code (예: "641901280,A09302381")
- 성분명: 한글/영문 병기
- 제조사 정보
- 허가 정보 및 분류

데이터 조인

- 약품식별 인공지능 개발을 위한 경구약제 이미지데이터
- 한국의약품안전관리원에서 제공하는 병용금기약물 데이터

파일 크기: 204MB
총 레코드 수: 542,996건
형식: CSV (15개 컬럼)

병용금기약물 정보는 두 약물 간의 상호작용 정보를 담고 있다:

약물 A 정보:
성분명A, 성분코드A
제품코드A, 제품명A
업체명A, 급여구분A

약물 B 정보:
성분명B, 성분코드B
제품코드B, 제품명B
업체명B, 급여구분B

병용금기 정보:
공고번호, 공고일자
금기사유 (상세 설명)

모델 학습 및 평가

모델 아키텍처

준지도학습

앙상블 / 멀티 모델

평가 비교

모델 아키텍처

YOLOv8

장점:

- 빠른 추론 속도
- 실시간 검출 가능
- End-to-end 학습
- 모바일 환경 적합

단점:

- 작은 객체 검출 어려움
- 정확도 한계

YOLOv8

- Image Size : 640x640
- Batch Size : 4
- Learning Rate : 0.01
- Epochs : 50
- Earlystop : 10

이 외 파라미터는 default값을 사용하였음.

Faster R-CNN

장점:

- 높은 검출 정확도
- 작은 객체 검출 우수
- 안정적인 성능
- 의료 영상에 적합

단점:

- 느린 추론 속도
- 높은 계산 비용

Faster R-CNN

- Backbone : ResNet-50, 101, Efficientnet-b0
- Image Size : 긴 변의 길이 ≤ 1333
- Batch Size : Resnet [4] | E-net [16]
- Learning Rate : Resnet [0.001] | E-net[0.0004]
- Weight decay : 0.0005
- Momentum : 0.9
- Step_size : 10
- Gamma : 0.9
- Epochs : 50
- Optimizer : SGD

YOLO + 분류모델

접근 방법:

- YOLO로 객체 위치 검출
- CNN 분류모델로 클래스 예측
- Two-stage 파이프라인

특징:

- 검출과 분류 역할 분리
- 분류 성능 개선 가능
- 복합적 접근법

분류모델

- Architecture : EfficientNet
- Classes : 93개
- Optimizer : Adam

YOLO + Faster R-CNN 앙상블

결합 방식:

- Weighted Box Fusion
- IoU 기반 박스 매칭
- 신뢰도 가중 평균


목표:

- 상호 보완적 예측
- robustness 향상

앙상블

- YOLO Weight : 0.6
- R-CNN Weight : 0.4
- IoU Threshold : 0.5
- NMS Threshold : 0.3
- 두 모델 bbox가 0.5 이상 겹치면 같은 객체
- 최종적으로 NMS 적용 시 0.3 이상 겹치는 bbox는 하나만 남김

준지도 학습



① 초기 모델 훈련


- 기존 데이터를 활용하여 모델 학습
- 기본 성능 확보
- Test 데이터 Score : 0.9692

② Pseudo-label 생성

- 모든 이미지에 예측 수행
- 기존의 label은 그대로 유지
- 기존에 없던 label에 대해 confidence > 0.9 예측 label 선택
- 새로 생긴 데이터를 랜덤으로 100개 추출 및 검증

③ 데이터 결합 및 재학습

- 원본 라벨 + Pseudo-label 결합
- 확장된 데이터셋으로 재학습
- 학습된 모델 활용하여 해당 과정 반복



준지도 학습 결과 비교



Before vs After 시각적 비교

기존 데이터를 활용한 모델 vs Pseudo-label을 포함한 모델의 검출 결과

Validation 이미지 중 target 데이터가 없는 객체를 포함하는 약 200개의 이미지에 대해 모델 예측을 비교
(활용 모델 : Faster R-CNN(resnet-101))

Bbox검출 개수

Before: 783개 After: 793 개

놓친 객체 수(총 bbox 개수 : 795개)


Before: 12 개 After: 2 개

Test 데이터에 대한 mAP 증가(약 3600개의 annotations)


Before: 0.96926 After: 0.97967

약 1% 가량의 mAP증가를 확인할 수 있었다.
이는, 기존보다 bbox 예측의 증가에 따른 증가로 보인다.


✖ Before



✔ After (Pseudo-label 추가)



앙상블(Ensemble)



🔗 앙상블 방법

- **Weighted Box Fusion**
- IoU 기반 박스 매칭
- 가중 평균으로 결합
- Non-Maximum Suppression 적용

	YOLOv8	Faster R-CNN	앙상블
mAP@0.5	0.9860	0.9832	0.9844
mAP@0.5-0.95	0.9740	0.9639	0.9693

앙상블 실험 결과:

- YOLOv8 단독: mAP X.XX
- Faster R-CNN + YOLOv8 앙상블: mAP Y.YY
 - 결과: 앙상블이 성능 향상을 보이지 않음"
- 앙상블 기법을 시도했으나 예상과 달리 성능이 개선되지 않았습니다.
 - 모든 앙상블이 성능을 보장하지 않음
 - 모델 간 상호보완성이 중요함 - 실험 검증의 중요성을 깨달음"


🌟 앙상블 효과

- Robustness 증가
- 해당 과정을 통해, OOD 데이터에 대해, 낮은 신뢰도로 예측.
 - ➡ OOD 데이터를 구분하기 쉬워짐.

멀티 모델




- **YOLOv8의 역할:**
이미지에서 약물의 위치를 정확하게 찾아내는 데 탁월한 성능
- **분류 모델의 역할:**
별도로 학습된 분류 모델(EfficientNet/ ResNet) 약물 이미지를 올바르게 분류하는 데 매우 뛰어난 정확도
- **문제점:**
각 모델이 개별적으로는 매우 뛰어난 성능을 보였지만, 둘을 결합한 파이프라인의 최종 성능은 오히려 단일 Faster RCNN 모델보다 낮았습니다.




분류 모델의 디테일한 튜닝 필요

검출 단계의 가 단순화 됨으로서 : YOLOv8이 100% 객체 탐지를 하였음


분류 단계의 오류: 탐지된 객체를 분류 하는데에 디테일한 튜닝 절략이 필요함 (향후 과제)



YOLO 8s 탐지/분류



YOLO 8s 탐지



Efficientnet 분류

평가 비교

① mAP@0.5-0.95를 기준으로 진행


- 여러 평가 지표 중, 학습 및 모델의 저장을 mAP를 기준으로 갱신함
- 이 중 가장 높은 성능을 보였던 YOLOv8 모델을 기준으로 추가 평가지표 확인

② 평가지표 설명 및 해석


	YOLOv8	Faster R-CNN	양상블
mAP@0.5-0.95	0.9740	0.9639	0.9693

Recall (재현율) : 모든 알약 객체 중 모델이 **알약**이라고 올바르게 탐지한 바운딩 박스의 비율.
(class일치, IoU 임계값)


Precision (정밀도) : 모델이 알약이라고 예측한 **모든 바운딩 박스** 중 실제로 올바른 바운딩 박스의 비율.
오탐지 객체 확인




- F1-Confidence Curve**
신뢰도 에 따른 **F1 점수**의 그래프,
- 모델 신뢰도 임계치를 0.769일 경우, **정밀도와 재현율 사이의 균형**
- 임계치 낮출 경우, 미탐지 ↓, 오탐지 ↑



- Recall-Confidence Curve:**
신뢰도의 값에 따른 **재현율**의 변화 그래프
- 0.8정도까지는 어느정도 미탐지가 많지 않지만, 그 이상일 경우에 미탐지가 급격히 증가



- Precision-Confidence Curve**
신뢰도에 따른 **정밀도**의 변화 그래프



- Precision-Recall Curve**
재현율에 따른 **정밀도**의 변화 그래프,
- 그래프의 곡선 아래 면적이 넓을수록, 좋은 성능
- 재현율을 높이려고 할 때에도, 정밀도가 크게 떨어지지 않는 모습을 보임.

해당 정보를 바탕으로, Confidence Score를 최종적으로 0.75로 설정

결론

결론

한계 및 향후 계획

결론

🎯 주요 성과

① 준지도학습 성공

- 10% 누락 데이터 pseudo-label 복원
- mAP 0.969 → 0.979 (약 1% 향상)
- 놓친 객체 수 12개 → 2개로 감소

② 데이터 불균형 해결

- AI-Hub 데이터 추가 활용
- 클래스별 최소 30개 객체 확보
- 데이터 증강으로 분포 안정화

③ 모델 성능 비교 분석

- YOLOv8: mAP@0.5-0.95 0.974 (최고)
- Faster R-CNN: 0.964
- 앙상블: 0.969 (성능 개선 미미)

④ 실 사용 프로그램 제작

- 병용 금기 약물 데이터를 활용
- 실제 경구약제의 주의점 및 금기약물을 표시

💡 프로젝트를 통해 깨달은 점

① 준지도학습의 한계와 가능성:

- 누락된 데이터가 많을 경우, 준지도학습이 매우 효과적인 방법
- 모델의 성능이 낮거나 데이터의 노이즈가 많을 경우, Pseudo-label의 품질이 낮아 모델 학습을 방해

② 파이프라인의 중요성:

- 팀원 간 동일한 학습 파이프라인(코드, 환경 설정 등)을 공유하지 않으면, 각자 개발한 모델을 활용, 비교하는 데 어려움이 발생
- 이는 모델 개발의 효율성을 크게 저해하는 요인으로, 향후 프로젝트에서는 초기 단계부터 통합 파이프라인 구축이 필수

③ 앙상블의 조건부 효과

- 단순히 여러 모델을 결합한다고 해서 항상 성능이 향상 ❌
- 모델 간 예측의 다양성이 충분하지 않으면 앙상블의 효과가 미미할 수 있다는 점을 확인

최종 모델

YOLOv8 nano

실시간성과 정확도 균형

인식 가능 약물

92종

4개 이상 약물 검출 가능

최종 성능(Test Score)

0.987

준지도학습 및 데이터 증강

한계 및 향후 계획

⚠ 프로젝트 한계점

📁 데이터 정제 및 라벨링 오류

- bbox 없는 객체에 대한 bbox 생성 완료
- 잘못된 클래스 라벨링 존재
- 부정확한 bbox 위치 (기존 bbox)

📊 클래스별 데이터 불균형

- 소수 클래스 정확도 저하
- 데이터 추가 및 증강으로도 한계

🔍 데이터의 한계

- '리피로우정' vs '비유피정'
- 한 면 정보만으로 분류 불가능
- 추가 데이터 수집 필요
- 다각도 촬영 유도 방안 필요

📱 학습 Class 부족

- 총 5000종에 가까운 데이터 존재
- 그 중 92종에 대한 class만 탐지 가능


🚀 향후 계획

📋 데이터 및 모델 개선

- 라벨링 정밀화
 - 기존 라벨 오류 식별 및 수정
 - 추가적인 준지도학습을 통해 오류 bbox 및 label 수정
- 손실 함수 개선
 - Focal Loss 도입
 - 소수 클래스 가중치 부여

🔧 서비스 확장 및 시스템 구축

- 모바일 앱 및 API 서버 구축
 - 실사용 환경 애플리케이션
 - API 서버 개발
 - 접근성 향상
- 모델 경량화
 - 더 많은 약물 카테고리 지원
 - 저사양 기기 최적화
 - 실시간 객체 탐지 성능 확보
 - 사용자 경험 개선



감사합니다.